Entregable 5: Proceso ETL con Pentaho

Presentado por: Danna Marilyn Barbosa Cardenas

Ventas Minoristas por Ciudad

1. Descripción del problema

Una cadena de tiendas minoristas ha recopilado datos de ventas en archivos CSV sin limpieza ni validación. El departamento de analitica necesita un proceso ETL que transforme estos datos crudos en información lista para análisis. Se utiliza Pentaho Data Integration (Spoon) como herramienta ETL.

2. Datos originales

El archivo contiene 500 registros de ventas entre 2022 y 2024, con ventas en 5 ciudades y 5 categorías de producto (Ropa, Alimentos, Hogar, Electrodomésticos, Tecnología).

Al validar los datos, se encontraron 0 registros donde el Total_Venta no coincide exactamente con Cantidad x Precio_Unitario.

3. Diseño del proceso ETL en Pentaho

Extraccion:
Se configuró un step "CSV file input" para leer el archivo con las siguientes opciones: separador = coma, encoding = UTF-8. Se definieron los tipos de cada campo (Fecha como Date, Cantidad como Integer, Precio_Unitario y Total_Venta como Number, Ciudad y Categoría como String).

Transformacion:
- Filter rows: Se filtraron registros con Cantidad <= 0 o Precio <= 0 para descartar datos inválidos.
- Calculator: Se crearon campos nuevos: Ingreso_Calculado (Cantidad x Precio), Ano, Mes, Trimestre y Dia de la semana.
- Value Mapper: Estandarización de nombres de ciudades y categorías.
- Select Values: Selección y renombrado de columnas finales.

Carga:
Se configuró un "Text file output" para generar un CSV limpio y estructurado. Alternativamente, se puede usar "Table output" para cargar directamente a una base de datos PostgreSQL o MySQL.

4. Flujo ETL

[CSV Input] -> [Filter Rows] -> [Calculator] -> [Value Mapper] -> [Select Values] -> [Sort Rows] -> [Group By] -> [Text Output] => [Reject Log]

5. Resultados del analisis

Ventas por ciudad:

Ciudad	Ventas	Transacciones	Ticket
Barranquilla	299011.37	115	2600.1
Bogotá	259371.96	94	2759.28
Cali	239883.91	105	2284.61
Cartagena	257183.47	99	2597.81
Medellín	253867.06	87	2918.01

Ventas por categoría:

Categoría	Ventas	Transacciones	Ticket
Alimentos	280384.39	107	2620.41
Tecnología	267589.66	100	2675.9
Electrodomésticos	255375.77	99	2579.55
Ropa	254308.06	89	2857.39
Hogar	251659.89	105	2396.76

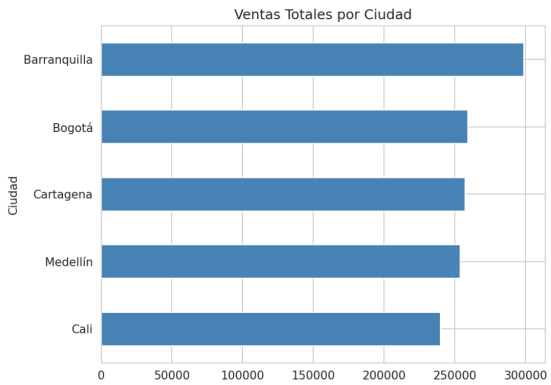

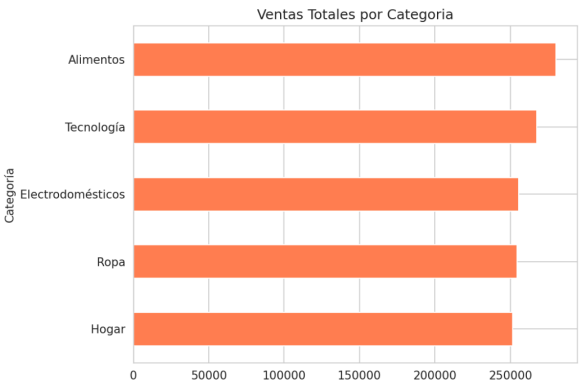

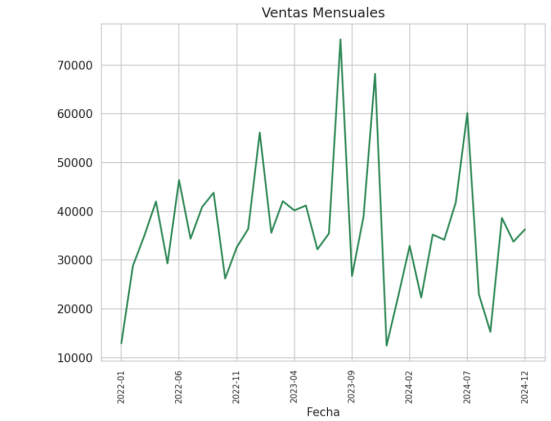

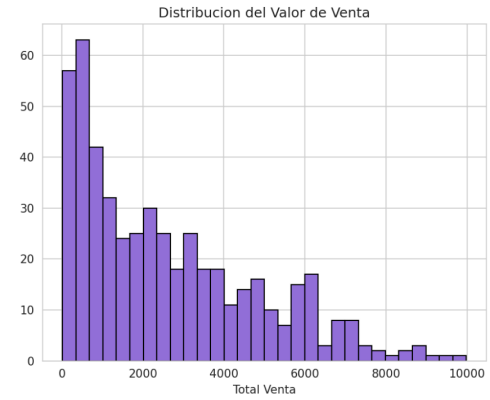

6. Conexión a herramienta de visualización

El CSV procesado se conectó a Power BI mediante la opción "Obtener datos > Texto/CSV". Se crearon gráficos de barras para ventas por ciudad y categoría, gráficos de líneas para tendencia mensual, y tarjetas KPI para las métricas principales (ventas totales, ticket promedio, etc.).
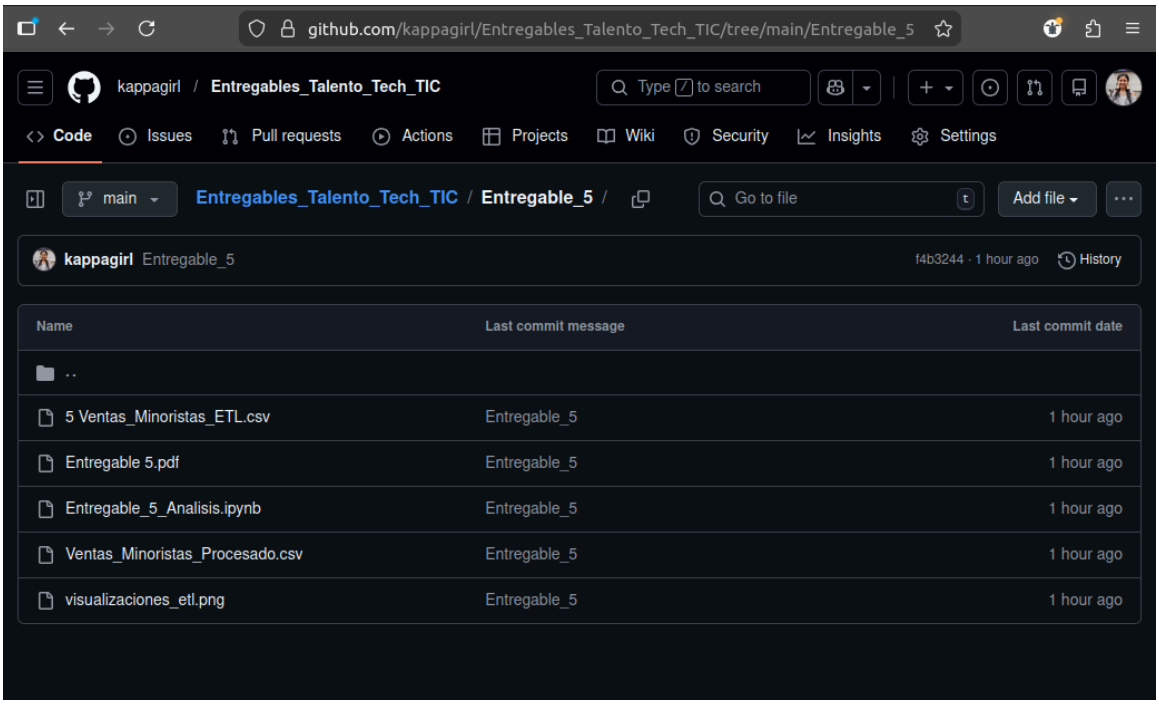
Repositorio:
https://github.com/kappagirl/Entregables_Talento_Tech_TIC/blob/main/Entregable_5/